

THÔNG TIN CHUNG CỦA BÁO CÁO

- Link YouTube video của báo cáo (tối đa 5 phút):

<https://youtu.be/wBSK-z4pPD0>

Link slides (dạng .pdf đặt trên Github của nhóm):

<https://github.com/nguyenvanminh281005/cs519>

- Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới
- Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in

- Họ và Tên: Nguyễn Văn Minh
- MSSV: 23520945



- Lớp: [CS519.Q11.KHTN](#)
- Tự đánh giá (điểm tổng kết môn): 9.5/10
- Số buổi vắng: 1
- Số câu hỏi QT cá nhân: 9
- Số câu hỏi QT của cả nhóm: 18
- Link Github:
<https://github.com/nguyenvanminh281005/cs519>
- Mô tả công việc và đóng góp của cá nhân cho kết quả của nhóm:
 - Tìm kiếm thông tin về NAS trên không gian CNN
 - Tìm kiếm kiến thức về không gian tìm kiếm kết hợp hybrid, thuật toán tối ưu đa mục tiêu.
 - Tìm kiếm thông tin về ứng dụng không gian hybrid cho các bài toán cụ thể
 - Tìm kiếm thông tin về bài toán phân loại, phân đoạn, ... trong y tế
 - Làm video YouTube

- Họ và Tên: Nguyễn Văn Hồng Thái
- MSSV: 23521418



- Lớp: [CS519.Q11.KHTN](#)
- Tự đánh giá (điểm tổng kết môn): 9.5/10
- Số buổi vắng: 1
- Số câu hỏi QT cá nhân: 9
- Số câu hỏi QT của cả nhóm: 18
- Link Github:
<https://github.com/nguyenvanminh281005/cs519>
- Mô tả công việc và đóng góp của cá nhân cho kết quả của nhóm:
 - Tìm kiếm thông tin về NAS trên không gian Transformers
 - Tìm kiếm kiến thức về không gian tìm kiếm kết hợp hybrid
 - Tìm kiếm thông tin về áp dụng các thuật toán để tối ưu hóa khi tìm kiếm trên không gian hybrid
 - Tìm kiếm thông tin về bài toán phân loại, phân đoạn, ... trong y tế
 - Làm video YouTube

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

**XÂY DỰNG PHƯƠNG THỨC TÌM KIẾM MẠNG NƠ-RON TỰ ĐỘNG (NAS) SỬ DỤNG
ZERO-SHOT TRÊN KHÔNG GIAN TÌM KIẾM KIẾN TRÚC LẠI (CNN + TRANSFORMER)**

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

**ZERO-SHOT NEURAL ARCHITECTURE SEARCH (NAS) METHOD BASED ON A HYBRID
SEARCH SPACE (CNN + TRANSFORMER)**

TÓM TẮT (Tối đa 400 từ)

Neural Architecture Search (NAS) đã đạt được những tiến bộ đáng kể trong việc tự động hóa thiết kế kiến trúc mạng nơ-ron. Tuy nhiên, các phương pháp NAS truyền thống vẫn gặp phải **ba thách thức chính**: (1) Chi phí tính toán lớn do phải huấn luyện và đánh giá nhiều kiến trúc tiềm năng; (2) Sự thiên vị trong quá trình huấn luyện supernet dẫn đến đánh giá sai hiệu suất các kiến trúc con; (3) Khó khăn trong việc tối ưu đồng thời cả độ chính xác và độ trễ trên các thiết bị phần cứng khác nhau.

Nghiên cứu này đề xuất một phương pháp NAS zero-shot dựa trên không gian tìm kiếm đa kiến trúc (hybrid CNN-Transformer), kế thừa và mở rộng các phương pháp tiên tiến BossNAS, BossNAS++ và HCT-Net.

Đóng góp chính của nghiên cứu bao gồm: (1) Xây dựng và huấn luyện siêu mạng hybrid sử dụng không gian tìm kiếm HyTra dạng fabric-like linh hoạt với kỹ thuật Masked Ensemble Bootstrapping, cho phép học biểu diễn đặc trưng mạnh mẽ thông qua cơ chế tự giám sát (MIM) mà không cần nhãn dữ liệu; (2) Phát triển bộ dự đoán độ trễ thích nghi đa phần cứng (MHLP - Multihardware Adaptive Latency Prediction) sử dụng cơ chế Multi-head Attention và chiến lược Meta-learning, cho phép thích nghi nhanh với thiết bị mới chỉ với ~10 mẫu; (3) Tích hợp MHLP vào quy trình tìm kiếm Masked Population-Centric Search để đánh giá ứng viên dựa trên sự đồng thuận của quần thể về độ chính xác và loại bỏ kiến trúc vi phạm ràng buộc độ trễ. (4) Định hướng cải tiến và ứng dụng NAS hybrid vào bài toán thực tế.

Phương pháp đề xuất được đánh giá trên các tập dữ liệu y tế (CVC-ClinicDB, CHAOS, ISIC2018) và chuẩn (CIFAR-10, CIFAR-100, ImageNet). **Kết quả kỳ vọng** là làm rõ tiềm năng của zero-shot NAS trong không gian kiến trúc lai, tạo ra các kiến trúc có độ chính xác cao, độ phức tạp thấp và khả năng tổng quát hóa tốt với chi phí huấn luyện tối thiểu, đặt nền tảng cho việc ứng dụng NAS hybrid vào các bài toán thị giác máy tính trong y tế và nhiều lĩnh vực khác.

GIỚI THIỆU (Tối đa 1 trang A4)

Bối cảnh và Động lực Nghiên cứu

Trong những năm gần đây, học sâu đã đạt được những thành tựu đột phá trong nhiều lĩnh vực, đặc biệt là thị giác máy tính và xử lý ngôn ngữ tự nhiên. Các mô hình như ResNet, EfficientNet, Vision Transformer (ViT)

đã thiết lập các mốc hiệu suất mới trên nhiều bài toán phân loại, phân đoạn và phát hiện đối tượng. Tuy nhiên, một vấn đề cốt lõi vẫn tồn tại: hiệu quả của các mô hình học sâu phụ thuộc rất lớn vào thiết kế kiến trúc mạng nơ-ron - một quá trình thủ công, tốn thời gian và đòi hỏi nhiều kinh nghiệm chuyên môn.

Neural Architecture Search (NAS) ra đời như một giải pháp tự động hóa quá trình thiết kế kiến trúc này. Các phương pháp NAS đầu tiên như NASNet, AmoebaNet đã chứng minh khả năng tìm ra các kiến trúc vượt trội hơn so với thiết kế thủ công. Tuy nhiên, chúng cũng để lại một vấn đề nghiêm trọng: chi phí tính toán khổng lồ. Ví dụ, NASNet tiêu tốn 48,000 giờ GPU để tìm kiếm kiến trúc tối ưu, tương đương hàng trăm nghìn đô la chi phí điện toán - một rào cản lớn đối với hầu hết các nhóm nghiên cứu và ứng dụng thực tế.

Các vấn đề tồn tại trong NAS hiện tại:

Vấn đề 1: Chi phí tính toán cao và thời gian tìm kiếm lâu. Các phương pháp NAS truyền thống như Reinforcement Learning-based và Evolutionary-based đều yêu cầu huấn luyện và đánh giá hàng ngàn kiến trúc tiềm năng, dẫn đến chi phí GPU và thời gian tìm kiếm không thể chấp nhận được trong nhiều trường hợp thực tế.

Vấn đề 2: Thiên vị huấn luyện siêu mạng (supernet bias). Các phương pháp weight-sharing NAS như DARTS, Once-for-All huấn luyện một siêu mạng chứa tất cả các kiến trúc con có thể. Tuy nhiên, do các kiến trúc con chia sẻ trọng số, quá trình huấn luyện thường thiên vị về một số kiến trúc nhất định (thường là các kiến trúc lớn, phức tạp), dẫn đến đánh giá sai lệch hiệu suất thực của các kiến trúc nhỏ gọn hơn.

Vấn đề 3: Tối ưu đa mục tiêu trên nhiều thiết bị phần cứng. Trong thực tế, một kiến trúc tốt không chỉ có độ chính xác cao mà còn phải đáp ứng các ràng buộc về độ trễ, bộ nhớ trên các thiết bị mục tiêu khác nhau (GPU, CPU, Edge devices). Các phương pháp hiện tại thường sử dụng bảng tra cứu tĩnh cho từng thiết bị, thiếu khả năng thích nghi nhanh với phần cứng mới mà không cần đo lường lại toàn bộ.

Vấn đề 4: Khó khăn trong không gian tìm kiếm đa kiến trúc. Các kiến trúc lai CNN-Transformer đang cho thấy tiềm năng lớn nhờ khả năng kết hợp trích xuất đặc trưng cục bộ (CNN) và mô hình hóa quan hệ toàn cục (Transformer). Tuy nhiên, việc xây dựng không gian tìm kiếm đa kiến trúc cho NAS hybrid vẫn còn nhiều thách thức: độ phức tạp tổ hợp cao, sự không đồng nhất giữa các loại toán tử, và thiếu tiêu chuẩn đánh giá thống nhất.

Các hướng tiếp cận hiện có và khoảng trống nghiên cứu:

Để giảm thiên lệch supernet, BossNAS và BossNAS++ đề xuất chiến lược Masked Ensemble Bootstrapping, huấn luyện supernet thông qua cơ chế tự giám sát (Masked Image Modeling - MIM) với các kiến trúc con được lấy mẫu ngẫu nhiên. Điều này giúp giảm sự thiên vị giữa các kiến trúc lớn và nhỏ. Tuy nhiên, phương pháp này chỉ được đánh giá trên không gian tìm kiếm đồng nhất (chỉ CNN hoặc chỉ Transformer), chưa mở rộng sang không gian hybrid.

Về tối ưu đa mục tiêu, HCT-Net kết hợp NAS với Hardware-aware constraints, sử dụng thuật toán pareto để cân bằng độ chính xác và độ trễ. Tuy nhiên, phương pháp này phụ thuộc vào bảng tra cứu độ trễ tĩnh cho từng

thiết bị, không có khả năng thích nghi với phần cứng mới mà không cần đo lường toàn bộ lại.

Research Gap: Chưa có phương pháp NAS nào kết hợp đồng thời (1) zero-shot evaluation để giảm chi phí, (2) chiến lược huấn luyện supernet giảm thiên lệch cho không gian hybrid CNN-Transformer, và (3) bộ dữ liệu đoán độ trễ thích nghi có khả năng meta-learning cho phần cứng mới. Đây chính là khoảng trống mà nghiên cứu này hướng đến giải quyết.

Input và Output:

Đầu vào (Input):

- Không gian tìm kiếm đa kiến trúc HyTra với các khối CNN (convolution, pooling), Transformer (self-attention, MLP) và các toán tử hybrid
- Supernet và chiến lược tối ưu EA với Masked Ensemble Bootstrapping
- Bộ dữ liệu đoán độ trễ MHLP (Multihardware Adaptive Latency Prediction) sử dụng GCN, Multi-head Attention và Meta-learning
- Các tập dữ liệu chuẩn và y tế: CVC-ClinicDB (phân đoạn polyp), CHAOS - Combined CT-MR (phân đoạn cơ quan bụng), ISIC2018 Task1 (phân đoạn tổn thương da), CIFAR-10, CIFAR-100, ImageNet.

Đầu ra (Output):

- Các kiến trúc mạng nơ-ron được tìm kiếm tự động với chi phí huấn luyện thấp, đáp ứng ràng buộc độ trễ trên các thiết bị đích
- Phương pháp NAS zero-shot có khả năng tổng quát hóa tốt trên không gian đa kiến trúc
- Đánh giá định lượng về độ chính xác, chi phí tìm kiếm, độ ổn định và khả năng ứng dụng trong y tế

MỤC TIÊU (Viết trong vòng 3 mục tiêu)

1. **Mục tiêu 1:** Xây dựng không gian tìm kiếm hybrid CNN–Transformer và siêu mạng huấn luyện zero-shot có đánh giá kiến trúc ít thiên lệch, correlation cao.
2. **Mục tiêu 2:** Phát triển bộ dữ liệu đoán độ trễ đa phần cứng (MHLP) dựa trên meta-learning, cho phép thích nghi nhanh với thiết bị mới chỉ với few-shot dữ liệu.
3. **Mục tiêu 3:** Tích hợp toàn bộ thành pipeline NAS zero-shot đa mục tiêu, tối ưu accuracy–latency trade-off và đánh giá hiệu quả trên các bài toán thị giác thực tế (lĩnh vực y tế).

NỘI DUNG VÀ PHƯƠNG PHÁP

Nội dung 1: Xây dựng Không gian Tìm kiếm và Siêu mạng Hybrid

Mục tiêu:

- Thiết kế không gian tìm kiếm đa kiến trúc HyTra dạng "tấm vải" (fabric-like) linh hoạt, kết hợp

CNN và Transformer

- Xây dựng và huấn luyện siêu mạng sử dụng kỹ thuật Masked Ensemble Bootstrapping
- Phân tích độ phức tạp, tính khả thi và khả năng giảm thiên lệch của phương pháp huấn luyện

Phương pháp thực hiện:

- Thiết kế không gian tìm kiếm HyTra ở cấp độ block và layer, kết hợp các toán tử CNN (convolution, pooling, residual connections) và Transformer (self-attention, multi-head attention, MLP)
- Kế thừa thiết kế "fabric-like" từ BossNAS, cho phép các đường kết nối linh hoạt giữa các block để tăng tính đa dạng kiến trúc
- Huấn luyện siêu mạng bằng kỹ thuật Masked Ensemble Bootstrapping mở rộng từ BossNAS++: các kiến trúc con được lấy mẫu ngẫu nhiên và học biểu diễn đặc trưng thông qua cơ chế tự giám sát Masked Image Modeling (MIM) mà không cần nhãn dữ liệu
- Thiết kế chiến lược lấy mẫu cân bằng để đảm bảo cả CNN và Transformer blocks đều được huấn luyện đầy đủ, tránh thiên lệch về một loại kiến trúc
- Đánh giá mức độ correlation giữa hiệu suất của các kiến trúc con trên supernet và hiệu suất thực sau khi huấn luyện độc lập (standalone training)

Kết quả dự kiến:

- Một không gian tìm kiếm hybrid CNN-Transformer HyTra có thể sử dụng cho gradient-based NAS
- Siêu mạng được huấn luyện với correlation cao (>0.7) giữa đánh giá trên supernet và hiệu suất thực
- Phân tích ưu điểm (tính linh hoạt, đa dạng) và hạn chế (độ phức tạp, thời gian huấn luyện) của không gian hybrid

Nội dung 2: Phát triển bộ dự đoán độ trễ thích nghi đa phần cứng (MHLP)

Mục tiêu:

- Thay thế các bảng tra cứu độ trễ tĩnh bằng mô hình dự đoán thích nghi có khả năng meta-learning
- Đánh giá khả năng thích nghi nhanh (few-shot adaptation) với thiết bị mới chỉ với ~ 10 mẫu

Phương pháp thực hiện:

- Thiết kế kiến trúc MHLP gồm 3 thành phần chính:
 - Graph Convolutional Network (GCN) để mã hóa cấu trúc kiến trúc mạng thành đặc trưng vector
 - Feature Encoder để mã hóa đặc trưng phần cứng (số nhân, băng thông bộ nhớ, kiến trúc chip)
 - Multi-head Attention để hợp nhất (fusion) đặc trưng kiến trúc và đặc trưng phần cứng

- Áp dụng chiến lược Meta-learning (Model-Agnostic Meta-Learning - MAML) để mô hình có khả năng thích nghi nhanh:
 - Huấn luyện trên nhiều thiết bị phần cứng khác nhau (GPU, CPU, Edge devices) như các "task" khác nhau
 - Tối ưu meta-parameters để mô hình có thể fine-tune nhanh trên thiết bị mới chỉ với vài mẫu (~10 mẫu)
- Thu thập dữ liệu huấn luyện: đo độ trễ thực tế của các kiến trúc mẫu trên nhiều thiết bị khác nhau
- Đánh giá độ chính xác dự đoán (Mean Absolute Percentage Error - MAPE) và khả năng thích nghi (số mẫu cần thiết để đạt $MAPE < 10\%$)

Kết quả dự kiến:

- Bộ dự đoán MHLP đạt $MAPE < 10\%$ trên các thiết bị đã huấn luyện
- Khả năng thích nghi nhanh: chỉ cần ~10 mẫu để đạt $MAPE < 15\%$ trên thiết bị mới
- So sánh ưu điểm về tính linh hoạt so với bảng tra cứu tĩnh và các phương pháp dự đoán hiện có

Nội dung 3: Tích hợp và đánh giá phương pháp NAS Zero-shot đa mục tiêu

Mục tiêu:

- Tích hợp MHLP vào quy trình tìm kiếm NAS để cân bằng độ chính xác và độ trễ
- Đánh giá toàn diện phương pháp đề xuất trên các bài toán thực tế

Phương pháp thực hiện:

- Tích hợp MHLP vào thuật toán tìm kiếm tiến hóa Masked Population-Centric Search của BossNAS++:
 - Đánh giá ứng viên dựa trên sự đồng thuận của quần thể (population consensus) về độ chính xác: các kiến trúc được đánh giá bởi nhiều kiến trúc con khác nhau trong supernet để giảm thiên lệch
 - Sử dụng MHLP để dự đoán độ trễ trên thiết bị đích và loại bỏ các kiến trúc vi phạm ràng buộc
 - Áp dụng Pareto optimization để tìm tập kiến trúc tối ưu cân bằng accuracy-latency tradeoff
- Thực nghiệm trên các tập dữ liệu:
 - Y tế: CVC-ClinicDB (phân đoạn polyp), CHAOS (phân đoạn cơ quan bụng), ISIC2018 (phân đoạn tổn thương da)
 - Chuẩn: CIFAR-10, CIFAR-100
- Các tiêu chí đánh giá:
 - Độ chính xác: so sánh với các phương pháp NAS hiện có (DARTS, PC-DARTS, FairNAS,

BossNAS)

- Chi phí tìm kiếm: tổng thời gian GPU, số lần đánh giá kiến trúc
- Độ ổn định: variance của độ chính xác qua nhiều lần chạy (3-5 runs)
- Khả năng thích nghi phần cứng: so sánh độ chính xác dự đoán độ trễ và số mẫu cần thiết
- Phân tích ablation study: đánh giá đóng góp của từng thành phần (Masked Ensemble Bootstrapping, MHLF, Population-centric search)

Kết quả dự kiến:

- Pipeline NAS zero-shot hoàn chỉnh cho không gian hybrid
- Độ chính xác cạnh tranh (trong khoảng $\pm 1-2\%$ so với best baseline) với chi phí tìm kiếm giảm đáng kể (10-100x)
- Chứng minh khả năng ứng dụng trong y tế với các kiến trúc cân bằng accuracy-latency phù hợp cho triển khai thực tế
- Phân tích định lượng các hạn chế và hướng cải tiến cho nghiên cứu tiếp theo

KẾT QUẢ MONG ĐỢI

- Đề xuất và hiện thực một phương pháp NAS zero-shot dựa trên không gian tìm kiếm đa kiến trúc (hybrid CNN-Transformer), kế thừa và mở rộng BossNAS/BossNAS++/HCT-Net
- Xây dựng bộ dự đoán độ trễ thích nghi đa phần cứng (MHLF) với khả năng meta-learning, cho phép thích nghi nhanh với thiết bị mới chỉ với ~ 10 mẫu
- Chứng minh tính khả thi và hiệu quả của phương pháp thông qua so sánh với các NAS hiện có, đồng thời tạo tiền đề cho ứng dụng NAS hybrid trong các bài toán thực tế, đặc biệt là y tế.

TÀI LIỆU THAM KHẢO (Định dạng DBLP)

- [1] White, Colin, et al., "Neural architecture search: Insights from 1000 papers", arXiv preprint arXiv:2301.08727, 2023.
- [2] Z. Yu et al., "HCT-net: hybrid CNN-transformer model based on a neural architecture search network for medical image segmentation", Tên Tạp chí/Hội nghị, 2023.
- [3] Zoph, Barret, and Quoc V. Le, "Neural Architecture Search with Reinforcement Learning", ICLR, 2017.
- [4] Liu, Hanxiao, et al., "DARTS: Differentiable Architecture Search", ICLR, 2019.
- [5] Li, Changlin, et al. "Bossnas: Exploring hybrid cnn-transformers with block-wisely self-supervised neural architecture search." Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021.
- [6] Wenchao Gu, et al.: *MS-NAS: Multi-Scale Neural Architecture Search for Medical Image Segmentation*. MICCAI 2020.
- [7] Yanfei Chen, et al.: *DPE-NAS: Differential Progressive Evolution for Neural Architecture Search in Medical Image Segmentation*. IEEE JBHI 2022.
- [8] Sungwoong Kim, et al.: *Scalable Neural Architecture Search for 3D Medical Image Segmentation*.

MICCAI 2019.

[9] Yuanzheng Jiang, et al.: *H-NAS: Hybrid Neural Architecture Search for 3D Medical Image Segmentation*. MICCAI 2020.

[10] Zhuotao Tian, et al.: *DeeperLab: Single-Shot Segmentation with Combined Semantic and Instance Predictions*. CoRR abs/1902.05093 (2019).

[11] Yiheng Zhang, et al.: *Customizable Architecture Search for Semantic Segmentation*. CVPR 2019.

[12] Chenxi Liu, et al.: *Auto-DeepLab: Hierarchical Neural Architecture Search for Semantic Image Segmentation*. CVPR 2019.

[13] Parker Hill, et al.: *NAS-U-Net: Neural Architecture Search for Medical Image Segmentation*. IEEE Access 2019.

[14] Yutong Xie, et al.: *NAS-Shape: Neural Architecture Search for Shape-aware Medical Image Segmentation*. MICCAI 2021.

[15] Huaijin Chen, et al.: *V-NAS: Neural Architecture Search for Volumetric Medical Image Segmentation*. 3DV 2019.

[16] Xinyu Gong, et al.: *Auto-GAN: Neural Architecture Search for Generative Adversarial Networks*. ICCV 2019.

[17] Chengxu Zuo, et al.: *C2FNAS: Coarse-to-Fine Neural Architecture Search for 3D Medical Image Segmentation*. CVPR 2020.

[18] Dong Yang, et al.: *Searching Learning Strategy with Reinforcement Learning for 3D Medical Image Segmentation*. MICCAI 2019.

[19] Zhanghui Kuang, et al.: *Fashion-Cut: Interactive Segmentation for Fashion Images*. ACM MM 2018.

[20] Xin Chen, et al.: *Progressive Differentiable Architecture Search: Bridging the Depth Gap between Search and Evaluation*. ICCV 2019.

[21] Yutong Xie, et al.: *CoTr: Efficiently Bridging CNN and Transformer for 3D Medical Image Segmentation*. MICCAI 2021.