

XÂY DỰNG PHƯƠNG THỨC TÌM KIẾM MẠNG NƠ-RON TỰ ĐỘNG (NAS) SỬ DỤNG ZERO-SHOT TRÊN KHÔNG GIAN TÌM KIẾM KIẾN TRÚC LẠI

*ZERO-SHOT NEURAL ARCHITECTURE SEARCH (NAS) METHOD
BASED ON A HYBRID SEARCH SPACE*

Nguyễn Văn Minh - 23520945
Nguyễn Văn Hồng Thái - 23521418

Tóm tắt

- **Lớp:** CS519.Q11.KHTN
- **Link Github của nhóm:** <https://github.com/nguyenvanminh281005/cs519>
- **Link YouTube video:**
<https://www.youtube.com/watch?v=wGjmmFUMoXM>
- **Ảnh + Họ và Tên:**
 - Nguyễn Văn Minh
 - Nguyễn Văn Hồng Thái



Giới thiệu

- Neural Architecture Search (NAS) đã đạt được những tiến bộ đáng kể trong việc tự động hóa thiết kế kiến trúc mạng nơ-ron. Tuy nhiên, các phương pháp NAS truyền thống vẫn gặp phải **ba thách thức chính**: (1) Chi phí tính toán lớn do phải huấn luyện và đánh giá nhiều kiến trúc tiềm năng; (2) Sự thiên vị trong quá trình huấn luyện supernet dẫn đến đánh giá sai hiệu suất các kiến trúc con; (3) Khó khăn trong việc tối ưu đồng thời cả độ chính xác và độ trễ trên các thiết bị phân cứng khác nhau.
- Nghiên cứu này đề xuất một phương pháp NAS zero-shot dựa trên không gian tìm kiếm đa kiến trúc (hybrid CNN-Transformer), kế thừa và mở rộng các phương pháp tiên tiến BossNAS, BossNAS++ và HCT-Net.

Các vấn đề tồn tại trong NAS hiện tại:

- Vấn đề 1:** Chi phí tính toán cao và thời gian tìm kiếm lâu.
- Vấn đề 2:** Thiên vị huấn luyện siêu mạng (supernet bias).
- Vấn đề 3:** Tối ưu đa mục tiêu trên nhiều thiết bị phân cứng.
- Vấn đề 4:** Khó khăn trong không gian tìm kiếm đa kiến trúc.

Research Gap: Chưa có phương pháp NAS nào kết hợp đồng thời (1) zero-shot evaluation để giảm chi phí, (2) chiến lược huấn luyện supernet giảm thiên lệch cho không gian hybrid CNN-Transformer, và (3) bộ dự đoán độ trễ thích nghi có khả năng meta-learning cho phần cứng mới. Đây chính là khoảng trống mà nghiên cứu này hướng đến giải quyết.

Mục tiêu

Mục tiêu tổng quát của đề tài là xây dựng một phương thức NAS hiệu quả, khắc phục các hạn chế của phương pháp hiện tại, và áp dụng vào một bài toán thực tế.

Mục tiêu 1: Xây dựng không gian tìm kiếm hybrid CNN–Transformer và siêu mạng huấn luyện zero-shot có đánh giá kiến trúc ít thiên lệch, correlation cao.

Mục tiêu 2: Phát triển bộ dự đoán độ trễ đa phân cứng (MHLP) dựa trên meta-learning, cho phép thích nghi nhanh với thiết bị mới chỉ với few-shot dữ liệu.

Mục tiêu 3: Tích hợp toàn bộ thành pipeline NAS zero-shot đa mục tiêu, tối ưu accuracy–latency trade-off và đánh giá hiệu quả trên các bài toán thị giác thực tế (lĩnh vực y tế).

Nội dung và Phương pháp

Nội dung 1: Xây dựng Không gian Tìm kiếm và Siêu mạng Hybrid

Phương pháp thực hiện:

- Thiết kế không gian tìm kiếm HyTra ở cấp độ block và layer, kết hợp các toán tử CNN (convolution, pooling, residual connections) và Transformer (self-attention, multi-head attention, MLP)
- Kế thừa thiết kế "fabric-like" từ BossNAS, cho phép các đường kết nối linh hoạt giữa các block để tăng tính đa dạng kiến trúc
- Huấn luyện siêu mạng bằng kỹ thuật Masked Ensemble Bootstrapping mở rộng từ BossNAS++: các kiến trúc con được lấy mẫu ngẫu nhiên và học biểu diễn đặc trưng thông qua cơ chế tự giám sát Masked Image Modeling (MIM) mà không cần nhãn dữ liệu
- Thiết kế chiến lược lấy mẫu cân bằng để đảm bảo cả CNN và Transformer blocks đều được huấn luyện đầy đủ, tránh thiên lệch về một loại kiến trúc
- Đánh giá mức độ correlation giữa hiệu suất của các kiến trúc con trên supernet và hiệu suất thực sau khi huấn luyện độc lập (standalone training)

Nội dung và Phương pháp

Nội dung 2: Phát triển bộ dự đoán độ trễ thích nghi đa phần cứng (MHLP)

Phương pháp thực hiện:

- Thiết kế kiến trúc MHLP gồm 3 thành phần chính:
 - Graph Convolutional Network (GCN) để mã hóa cấu trúc kiến trúc mạng thành đặc trưng vector
 - Feature Encoder để mã hóa đặc trưng phần cứng (số nhân, băng thông bộ nhớ, kiến trúc chip)
 - Multi-head Attention để hợp nhất (fusion) đặc trưng kiến trúc và đặc trưng phần cứng
- Áp dụng chiến lược Meta-learning (Model-Agnostic Meta-Learning - MAML) để mô hình có khả năng thích nghi nhanh:
 - Huấn luyện trên nhiều thiết bị phần cứng khác nhau (GPU, CPU, Edge devices) cho các "task" khác nhau
 - Tối ưu meta-parameters để mô hình có thể fine-tune nhanh trên thiết bị mới chỉ với ~10 mẫu
- Thu thập dữ liệu huấn luyện: đo độ trễ thực tế của các kiến trúc mẫu trên nhiều thiết bị khác nhau
- Đánh giá độ chính xác dự đoán và khả năng thích nghi (số mẫu cần thiết để đạt $MAPE < 10\%$)

Nội dung và Phương pháp

Nội dung 3: Tích hợp và đánh giá phương pháp NAS Zero-shot đa mục tiêu

Phương pháp thực hiện:

- Tích hợp MHLF vào thuật toán tìm kiếm tiến hóa Masked Population-Centric Search của BossNAS++:
 - Đánh giá ứng viên dựa trên sự đồng thuận của quần thể về độ chính xác
 - Sử dụng MHLF để dự đoán độ trễ trên thiết bị đích và loại bỏ các kiến trúc vi phạm ràng buộc
 - Áp dụng Pareto optimization để tìm tập kiến trúc tối ưu cân bằng accuracy-latency tradeoff
- Thực nghiệm trên các tập dữ liệu: CVC-ClinicDB, CHAOS, ISIC2018
- Các tiêu chí đánh giá:
 - Độ chính xác: so sánh với các phương pháp NAS hiện có (DARTS, PC-DARTS, FairNAS, BossNAS)
 - Chi phí tìm kiếm: tổng thời gian GPU, số lần đánh giá kiến trúc
 - Độ ổn định: variance của độ chính xác qua nhiều lần chạy (3-5 runs)
 - Khả năng thích nghi phân cứng: so sánh độ chính xác dự đoán độ trễ và số mẫu cần thiết
- Phân tích ablation study: đánh giá đóng góp của từng thành phần (Masked Ensemble Bootstrapping, MHLF, Population-centric search)

Kết quả dự kiến

Kết quả Dự kiến (Expected Outcomes)

- Đề xuất và hiện thực một phương pháp NAS zero-shot dựa trên không gian tìm kiếm đa kiến trúc (hybrid CNN-Transformer), kế thừa và mở rộng BossNAS/BossNAS++/HCT-Net
- Xây dựng bộ dự đoán độ trễ thích nghi đa phần cứng (MHLP) với khả năng meta-learning, cho phép thích nghi nhanh với thiết bị mới chỉ với ~ 10 mẫu
- Chứng minh tính khả thi và hiệu quả của phương pháp thông qua so sánh với các NAS hiện có, đồng thời tạo tiền đề cho ứng dụng NAS hybrid trong các bài toán thực tế, đặc biệt là y tế.

Tài liệu tham khảo

Tài liệu Tham khảo (References)

- [1]. White, Colin, et al., "Neural architecture search: Insights from 1000 papers", arXiv preprint arXiv:2301.08727, 2023.
- [2]. Z. Yu et al., "HCT-net: hybrid CNN-transformer model based on a neural architecture search network for medical image segmentation", Tên Tạp chí/Hội nghị, 2023.
- [3]. Zoph, Barret, and Quoc V. Le, "Neural Architecture Search with Reinforcement Learning", ICLR, 2017.
- [4]. Liu, Hanxiao, et al., "DARTS: Differentiable Architecture Search", ICLR, 2019.
- [5]. Li, Changlin, et al. "Bossnas: Exploring hybrid cnn-transformers with block-wisely self-supervised neural architecture search." Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021.